ST5202 Applied Regression Analysis
期末复习 · Final Review (v2 · 基于完整讲义)

Lecture 4 (Multiple Comparisons) → Lecture 9 (Generalized Linear Models)
Open-Book · Pen-and-Paper · Calculator Allowed · No R
(读 R 输出 · 理解概念 · 手动计算)

目录 **Contents**

1. 总览与课程框架 Overview
2. L4 Multiple Comparisons 多重比较
3. L5 ANCOVA & 非线性预测项 Non-linear Predictors
4. L6 Model Selection 模型选择(含 Ridge/LASSO)
5. L7 Regression Diagnostics 回归诊断
6. L8 Remedial Measures 补救措施 (WLS/Ridge/PCR/Box-Cox)
7. L9 Generalized Linear Models 广义线性模型
8. R 输出逐行解读 R Cheat-Sheet
9. 高频公式速查卡 Formula Sheet ★★★
10. 七种题型应答模板 Question Templates
11. 考前 48 小时 Checklist
12. 中英术语对照 Glossary

1. 总览 Overview — 课程框架

一条主线:基础 LRM($y = X\beta + \epsilon$)→ **当我们同时做多组检验(L4)或扩展模型(L5)时如何推断 → 选择模型(L6) → 诊断模型(L7) → 补救问题(L8) → 扩展到非正态响应(L9 GLM)**。

模块	核心问题	关键工具	重要示例
L4 Multiple Comparisons	多组比较如何控制 FWER?	Scheffé / Tukey / Dunnett / Bonferroni	Meat Storage, Kenton Food
L5 ANCOVA + Non-linear	含 factor+covariate 或非线性?	Dummy + covariate, 多项式, log, piecewise	Cracker, Salable Flowers, Piecework, Cherry
L6 Model Selection	选哪些变量?高维怎么办?	AIC/BIC/Cp/CV + Ridge/LASSO/SCAD/MCP	Insurance, Pullstrength
L7 Diagnostics	假设是否成立?异常点?	3 种残差, leverage, Cook's D	Surgical Unit
L8 Remedial Measures	异方差/共线/非正态?	WLS + VIF+Ridge+PCR + VST + Box-Cox	WBP, BP, Dementia, Animal, Ulcer
L9 GLM	响应非正态(0/1 或 count)?	Logistic + Poisson	Challenger, Aneurysms, Mine Fracture

2. L4 Multiple Comparisons 多重比较

2.1 为什么要多重比较?

对 m 个检验,每个用 α → **Family-Wise Error Rate (FWER)** $\approx 1-(1-\alpha)^m$。例:$\alpha = 0.05, m = 100 \Rightarrow$ 至少一个错误拒绝的概率 $= 1 - 0.95^{100} \approx \mathbf{0.9941}$(近乎必错)。

FWER 定义:$P\Big(\bigcup_{j\in C}\{T_j \geq c_j\}\Big)$。目标:找 critical value 把此概率控制在 α。

2.2 通用检验统计量

★ **TEST STATISTIC FOR ANY CONTRAST**

$$T_a = \frac{a^\top \hat\theta}{\sqrt{a^\top \hat\Sigma_\theta\, a}}$$

其中 $\hat\theta$ 是估计向量(如 $\hat\mu$ 或 $\hat\beta$),$\hat\Sigma_\theta$ 是其 var-cov 矩阵。

2.3 四大准则 Four Criteria ★必考

准则	适用场景	Critical value (two-sided)
Scheffé	任何 contrast,含数据驱动 / general exploration;q 个 group means	$c_\alpha = \sqrt{m_1 F_{m_1,m_2}(\alpha)}$;主效应场合 $m_1 = a-1,\ m_2 = n-a$: $\sqrt{(a-1)F_{a-1,n-a}(\alpha)}$
Tukey (HSD)	全部 pairwise,**要求 equal n**	$c_\alpha = q_{a,\,n_{err}}(\alpha)/\sqrt{2}$(Studentized range quantile)
Dunnett	所有 treatment vs 1 个 control	查 Dunnett 表 $d_{a,\nu,\alpha}$;unequal n 时乘 $m_j = 1 + 0.07(1 - n_j/n_1)$
Bonferroni	有限个 pre-specified contrasts/tests	$t_{n-p}(\alpha/(2k))$;**simultaneous p-value =** $k\times$ **individual p**

★ **决策规则 DECISION RULE**

$$\text{Reject } H_0 \iff |T_a| > c_\alpha, \qquad \text{CI: } a^\top\hat\theta \pm c_\alpha \cdot \sqrt{a^\top \hat\Sigma_\theta a}$$

2.4 Studentized Range 公式

对 a 个 groups,$n_{err} = n - a$:

$$q_{a,n_{err}} = \frac{\sqrt{n}\,(\max \bar Y_i - \min \bar Y_i)}{\hat\sigma} = \sqrt{2}\,\max|T_{ij}|$$

2.5 Scheffé 单侧 one-sided 调整(Supplement L4)

将 α 替换为 2α:$c_{\text{one-sided}} = \sqrt{(a-1)F_{a-1,\,n_{err}}(2\alpha)}$。

2.6 关键关系:Overall F vs Contrasts

易错点: Overall ANOVA F 可以显著,而没有一个 inspected contrast 显著(反之亦然)。overall F 等价于"Scheffé 下至少一个 contrast 显著"的 dual。

2.7 如何选准则?(高频判断题)

口诀:

1. 仅限 **pairwise + equal n → Tukey**(通常最紧)
2. 所有 **possible contrasts(含事后探索) → Scheffé**
3. **vs control → Dunnett**
4. k **个预先指定 +** k **小** → 比较 **Bonferroni** 与 Tukey/Scheffé,c 小者胜
5. **directional(one-sided)且非 pairwise** → Tukey 不能直接用

2.8 R 实现

```
fit <- aov(y ~ group, data=d)
TukeyHSD(fit)                              # Tukey HSD
pairwise.t.test(y, group, p.adjust="bonferroni")
library(multcomp); summary(glht(fit, linfct=mcp(group="Dunnett")))
# Scheffé: 手动构造 C matrix
C <- rbind(c(1,-1,0,0))                    # contrast matrix
bhat <- coef(fit); VC <- vcov(fit)
est  <- C %*% bhat; se <- sqrt(diag(C %*% VC %*% t(C)))
t_stat <- est/se
# 比较 |t_stat| 与 Scheffé critical
```

2.9 例题(Past Paper Q1 类型)

3 brands, `lm(y~brand)` 给出 brand2 est=−15.8 (SE=2.498), brand3 est=5.2 (SE=2.498), $n-p=12$。预期 $\mu_2<\mu_1<\mu_3$(2 个 one-sided,$k=2$)。

- $t_1^*=-6.325;\ t_2^*=2.082$
- Bonferroni one-sided critical $=t_{12}(0.05/2)=\mathbf{2.1788}$
- $|t_1^*|>2.1788\rightarrow$ reject($\mu_2<\mu_1$ 成立);$|t_2^*|<2.1788\rightarrow$ not reject

3. L5 ANCOVA & 非线性预测项 注意

⚠️ 注意:L5 不是 general linear test 专题!它讲的是两类模型扩展:
(i) ANCOVA(协方差分析) — 同时含 factor 和 continuous covariate
(ii) 非线性预测项 — 多项式 / log-log / inverse / piecewise linear

3.1 ANCOVA 基本模型

$$y_i=\beta_0+\sum_{j=2}^{k}\alpha_j u_{ij}+\gamma\, x_i+\epsilon_i$$

u_{ij} = factor 的 dummy;x_i = covariate(协变量);γ = 协变量斜率(假定各组相同)。

3.2 Comparison-of-regression-functions 模型(各组斜率不同)

$$Y=\beta_0+\sum_j\alpha_jU_j+\beta X+\sum_j\xi_jU_jX+\epsilon$$

- 不同 **intercept**: $\beta_0+\alpha_j$
- 不同 **slope**: $\beta+\xi_j$
- 检验"平行性"$H_0:\xi_j=0\ \forall j$

3.3 "When x is held at its mean" 常用技巧

令 $z=x-\bar{x}$,模型 $y=\beta_0+\beta_2T_2+\beta_3T_3+\alpha z+\gamma_1T_2z+\gamma_2T_3z$。
$z=0$ 时:**group means = Intercept + treatment effects**。Contrast $\mu_2-\mu_1=\beta_2$,$\mu_3-\mu_1=\beta_3$。

3.4 非线性预测项 Non-linear predictor terms

类型	模型形式	注意
Polynomial 多项式	$y_i=\beta_0+\beta_1(x_i-\bar{x})+\beta_2(x_i-\bar{x})^2+\cdots$	**中心化**减少共线性;但最高阶系数与是否中心化无关
Inverse 反函数	$y_i=\beta_0+\beta_1(1/x_i)+\epsilon_i$	适用渐近水平关系
Log-log	$\log y=\beta_0+\beta_1\log x+\epsilon$	弹性解释;$\beta_1=x$ 每增 1% 导致 y 变 $\beta_1\%$
Piecewise linear 分段线性	$y_i=\beta_0+\beta_1x_i+\alpha_1(x_i-c)^+ +\epsilon_i$	$x<c$ 时斜率 β_1,$x\geq c$ 时 $\beta_1+\alpha_1$;检验 $H_0:\alpha_1=0$

重点:"linear" in LRM 指"linear in **parameters**"。$y=\beta_0+\beta_1x^2$ 仍然是线性模型;$y=\beta_0\,x^{\beta_1}$ 不是。

3.5 R 实现

```
lm(y ~ x + type)                    # ANCOVA (same slope)
lm(y ~ x * type)                    # Different slopes (interaction)
lm(y ~ x + I(x^2) + I(x^3))         # Polynomial
lm(y ~ I(1/x))                      # Inverse
lm(log(y) ~ log(x1) + log(x2))      # Log-log
z = (x - 250) * (x >= 250)          # Piecewise at c=250
lm(y ~ x + z)
```

3.6 anova() 顺序问题

顺序依赖! `anova(lm(y~A*B))` 输出的是 **Type I (sequential) SS**,A 先进、B 后进,交互最后。若想要"加入 B 后 A 的独立贡献",需要反序或用 `drop1()`。

4. L6 Model Selection 模型选择(含正则化)

4.1 Bias-Variance 分解

$$\mathrm{MSE}=\mathrm{Var}+\mathrm{bias}^2$$

SPSE (Sum of Predicted Squared Error):

$$\mathrm{SPSE}=n\sigma^2+|M|\sigma^2+\sum_i(\mu_i-\mu_{iM})^2$$

4.2 选择准则 Criteria ★

Criterion	公式	方向
R^2	SSR/SST	越大越好 *但会一直随 p 增*
Adjusted R^2	$R_a^2 = R^2 - \dfrac{p}{n-p-1}(1-R^2)$	越大越好
Mallow's C_p	$C_p = \dfrac{SSE_M}{\hat\sigma^2_{\text{full}}} - n + 2\lvert M\rvert$	越小越好;理想 $E[C_p] \approx \lvert M\rvert$
AIC	$-2\log L + 2j_M$;LRM: $n\log\hat\sigma_M^2 + 2j_M + C$	越小越好
BIC	$-2\log L + j_M \log n$	越小越好(更严,倾向 sparse)
EBIC	$\text{BIC} + 2\gamma\log\binom{p}{j_M},\ \gamma = 1 - \dfrac{\log n}{2\log p}$	高维场合
k**-fold CV**	$\frac{1}{n}\sum(y_i - x_i^\top\hat\beta^{(-\text{fold}(i))})^2$	越小越好
LOO CV	$\frac{1}{n}\sum(y_i - x_i^\top\hat\beta^{(-i)})^2$	越小越好

4.3 三种逐步算法 Stepwise

- **Forward**: null → 每步加入使 AIC 最小的变量
- **Backward**: full → 每步删除最不显著的
- **Stepwise (both)**: 每步先考虑加再考虑删

4.4 读 stepAIC 输出 ★高频

```
Step: AIC=276.73
y ~ x3
        Df     SSR     SSE
+ x2     1   52502    2210      ← SSR 最大 → 候选
+ x4     1   10639   44073
<none>                  54712   ← 当前模型 SSE
+ x1     1    2887   51825
```

- **SSR** = $SSE_{\text{old}} - SSE_{\text{new}}$(减少量)
- 候选 = SSR 最大行
- 加入条件:新 AIC < `<none>` AIC
- 近似:$\Delta\text{AIC} \approx n\ln(SSE_{\text{new}}/SSE_{\text{old}}) + 2$

4.5 正则化 / Shrinkage(L6 已引入,L8 继续用) ★

★ 惩罚最小二乘

$$\min_\beta\ \tfrac{1}{n}\|y - X\beta\|^2 + p_\lambda(\beta)$$

方法	惩罚	变量选择	特性
Ridge	$\lambda\sum\beta_j^2$	否	凸;所有 coef 缩小;允许 $p > n$
LASSO	$\lambda\sum\lvert\beta_j\rvert$	是 (sparse)	凸;ℓ_1;同时选变量和估计
Adaptive LASSO	$\lambda\sum w_j\lvert\beta_j\rvert,\ w_j = \lvert\hat\beta_j\rvert^{-1}$	是	凸;oracle 性质
SCAD	Smoothly Clipped AD	是	非凸;大系数无惩罚
MCP	Minimax Concave	是	非凸;$\lvert\beta\rvert > \gamma\lambda$ 时惩罚为 0

4.6 λ 的选择

- **Prediction** 为主 → CV / GCV 选 $\lambda_{\min}$(CV error 最小)
- **Variable identification** 为主 → BIC / EBIC
- 保守(更少假阳性) → `lambda.1se` (1 SE rule)

4.7 R 实现

```
library(MASS)
stepAIC(lm(y~1, data=d), scope=list(upper=lm(y~., data=d)), direction="forward")
stepAIC(lm(y~., data=d), direction="backward")
stepAIC(lm(y~1, data=d), scope=list(upper=lm(y~., data=d)), direction="both")
AIC(fit, k=2);  AIC(fit, k=log(n))     # BIC via k=log(n)

library(boot); cv.glm(d, glmfit, K=10)$delta   # k-fold CV

library(glmnet)
cv <- cv.glmnet(X, y, alpha=1)          # 1=LASSO, 0=Ridge
cv$lambda.min;  cv$lambda.1se
coef(cv, s="lambda.min")
predict(cv, newx=X_test, s="lambda.min")
```

5. L7 Regression Diagnostics 回归诊断 重点

5.1 Hat Matrix & Leverage

$$H = X(X^\top X)^{-1}X^\top,\quad h_{ii} = x_i^\top(X^\top X)^{-1}x_i,\quad \sum_i h_{ii} = p$$

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii})$$

- $h_{ii} \in [0,1]$,平均 $= p/n$
- 阈值:$h_{ii} > 2p/n$ → high leverage
- 仅依赖 X,不依赖 y

5.2 三类残差 Three Residuals ★必背

★ 核心公式 — 3 RESIDUALS

$$\text{Raw: } e_i = y_i - \hat y_i$$

$$\text{Studentized (internal): } r_i' = \frac{e_i}{\hat\sigma\sqrt{1-h_{ii}}}$$

$$\text{Studentized Deleted (external): } r_i^* = \frac{y_i - \hat y_i^{(i)}}{\hat\sigma_{(i)}\sqrt{1-h_{ii}}} = r_i'\sqrt{\frac{n-p-1}{n-p-r_i'^2}} \sim t_{n-p-1}$$

5.3 Cook's Distance

$$d_i = \frac{(\hat\beta^{(i)} - \hat\beta)^\top (X^\top X)(\hat\beta^{(i)} - \hat\beta)}{p\,\hat\sigma^2} = \frac{r_i'^2}{p} \cdot \frac{h_{ii}}{1 - h_{ii}}$$

- 综合 inconsistency($r_i'^2$)+ leverage(h_{ii})→ influence
- 阈值:$d_i > 1$ 严重;Tutorial 常用 $d_i > 0.1$ 做筛选

5.4 三个概念必分清 ★

概念	英文	度量	解释
高杠杆	high leverage	h_{ii}	X 空间位置极端(x 远离均值)
不一致/异常	outlier / inconsistency	$\lvert r_i^* \rvert$	y 偏离模型预测
高影响	high influence	d_i	删除后对 $\hat\beta$ 变化大

5.5 系统诊断 Systematic Diagnostics(全局)

1. `plot(yhat, r)` → **homogeneity**(漏斗形 → 异方差;曲线形 → 非线性)
2. `qqnorm(rsta)` → **normality**(两端偏离 → 重尾/偏态)
3. `plot(x_j, r)` → 该 x_j 是否需非线性项 / 是否有遗漏变量
4. `plot(time, r)` → 独立性

5.6 局部诊断 Local Diagnostics(个体)

1. QQ plot of h_{ii}、$|r_i^*|$、d_i 各自找极值
2. 阈值筛查
3. Formal outlier test:造 dummy u_i(第 i 个观测 = 1),拟合 `lm(y~X+u_i)` ,检验 u_i 系数
4. 同时检验 m 个点用 **Bonferroni**: $t_{n-p-m}(\alpha/(2m))$

5.7 Surgical Unit 例 Summary(讲义标杆例)

n=54,4 预测 (X1 clot, X2 prog, X3 enzyme, X4 liver),响应 log-survival。

- 按 h_{ii} 标出:13,17,18,28,32,38,42,43,50,52
- 按 $|r^*|$:37,9,27,38
- 按 d_i:22,28,37,38
- Bonferroni 联合检验后,除 obs 37 外都显著

5.8 R 代码(通用)

```
fit  <- glm(y ~ X, data=d)            # 或 lm()
yhat <- fitted(fit)
r    <- residuals(fit, type="pearson")
h    <- hatvalues(fit)
rsta <- rstandard(fit)                 # internally studentized r_i'
rstu <- rstudent(fit)                  # externally studentized r_i*
cook <- cooks.distance(fit)

par(mfrow=c(2,2))
plot(yhat, r);  qqnorm(rsta);  qqnorm(h);  qqnorm(rstu);  qqnorm(cook)

# 阈值筛
h[h > 2*p/n];  rstu[abs(rstu) > 2*sd(rstu)];  cook[cook > 0.1]

# Bonferroni simultaneous outlier test
qt(alpha/(2*m), n-p-m, lower.tail=FALSE)
```

6. L8 Remedial Measures 补救措施

6.1 四类问题四类 remedy

问题	补救
Nonlinearity 非线性	多项式/log/inverse/piecewise (从 L5)
Non-constant variance 异方差	WLS / 方差稳定变换 VST / Box-Cox
Multi-collinearity 共线	删变量 / Ridge / PCR
Non-normality 非正态	Box-Cox / 变换

6.2 WLS 加权最小二乘 ★

$$\hat\beta_W = (X^\top W X)^{-1} X^\top W y, \quad W = \mathrm{diag}(w_i),\ w_i = 1/\sigma_i^2$$

$$\mathrm{Var}(\hat\beta_W) = \sigma^2 (X^\top W X)^{-1}$$

目标:$\min \sum w_i (y_i - x_i^\top \beta)^2$

6.3 估计权重的方法 Weight Estimation

方法 A(无重复,讲义主方法):$\log|r_i|$ 对 $\log \hat y_i$ 回归 → $\log|r_i| = \alpha_0 + \alpha_1 \log \hat y_i$,则

$$w_i = \hat y_i^{-2\hat\alpha_1}$$

方法 B:$|r_i|$ 对 $\hat y_i$ 线性回归 → $w_i = 1/\widehat{|r_i|}^2$

方法 C(有重复):每组 n_i 个观测,组内样本方差 s_i^2 → $w_i = n_i/s_i^2$

> **诊断加权模型**:画 $\sqrt{w_i}\, r_i$ vs $\sqrt{w_i}\, \hat y_i$,应该 **无明显 pattern**(null pattern)。
> 陷阱:R^2 不能用来比较 WLS 与 OLS。

6.4 VIF ★核心

★ 方差膨胀因子

$$\mathrm{VIF}_j = \frac{1}{1-R_j^2}$$

R_j^2 = auxiliary regression (x_j 对其他 X 的回归) R^2

等价形式(从 lm 输出手算):

$$\mathrm{VIF}_j = \frac{\mathrm{Var}(\hat\beta_j)\cdot\sum_i(x_{ji}-\bar x_j)^2}{\hat\sigma^2} = \frac{SE(\hat\beta_j)^2\,\sum(x_{ji}-\bar x_j)^2}{\hat\sigma^2}$$

阈值:**VIF > 5**(严格)或 **> 10**(宽松)→ 严重共线。

两预测时 **VIF** 相等:$R_2^2 = R_3^2 = r_{23}^2$(对称),故 $\mathrm{VIF}_2 = \mathrm{VIF}_3 = 1/(1-r^2)$。

6.5 Ridge Regression 岭回归

$$\hat\beta_{\text{ridge}} = (X^\top X + \lambda I)^{-1}X^\top y$$

$$\min \|y - X\beta\|^2 + \lambda\|\beta\|^2$$

- 有偏($\lambda > 0$)但方差更小
- λ 越大 → coef 越靠 0(不为 0)
- λ 由 **GCV** 选(GCV 最小)
- X 需标准化

```
library(MASS)
r <- lm.ridge(y ~ ., data=d, lambda=seq(0,50,0.1))
plot(r$lambda, r$GCV, type="l")
lambda.best <- r$lambda[which.min(r$GCV)]
```

6.6 PCR 主成分回归

谱分解 $X^\top X = Q\Delta Q^\top$($\tau_j$ = 特征值);主成分 $Z = XQ$:

$$\hat\beta_{\text{pcr}} = \sum_{j=1}^{k}\frac{q_j q_j^\top y}{\tau_j}, \quad k \le p$$

- $k = p$ 时 = OLS
- $k < p$ 时:丢弃小特征值(共线方向)→ 方差降、偏差升
- 与 Ridge 对比:Ridge 是连续 shrinkage,PCR 是硬截断

```
library(pls)
pcr.fit <- pcr(y ~ ., data=d, scale=TRUE, validation="CV")
validationplot(pcr.fit, val.type="MSEP")
```


6.7 方差稳定变换 Variance Stabilizing Transformation

一般原理:若 $\sigma(\mu)$ 已知,找 g 使 $g'(\mu) \propto 1/\sigma(\mu)$。

响应类型	$\sigma^2 \propto$	变换
比例 Proportion $\in [0,1]$	$\mu(1-\mu)$	$\arcsin\sqrt{Y}$
计数 Count	μ	$\sqrt{Y}$
右偏 Right-skewed	μ^2	$\log Y$
严重右偏	μ^4	$1/Y$

6.8 Box-Cox Transformation ★

$$g_\lambda(Y) = \begin{cases}(Y^\lambda - 1)/\lambda, & \lambda \ne 0\\ \log Y, & \lambda = 0\end{cases}$$

若 $\sigma \propto \mu^\alpha$,则最佳 $\lambda = 1-\alpha$。

$\alpha \to \lambda$ 对应表(讲义考点):

α	3	2	3/2	1	1/2	0	-1/2	-1
$\lambda = 1-\alpha$	-2	-1	-1/2	**0 (log)**	**1/2 (√)**	1 (none)	3/2	2

6.9 α 的估计

- **Method I**:$\log s_i$ 对 $\log \bar y_i$ 回归(有重复时) / $\log|r_i|$ 对 $\log \hat y_i$(无重复时)。斜率 $= \hat\alpha$。
- **Method II**:最小化 $\max_i(s_i/\bar y_i^\alpha)/\min_i(s_i/\bar y_i^\alpha)$(在候选 α 中网格搜索)。

6.10 R 实现

```
# WLS
fit = lm(y ~ X)
wreg = lm(log(abs(resid(fit))) ~ log(fitted(fit)))
w = fitted(fit)^(-2*coef(wreg)[2])
fit.w = lm(y ~ X, weights = w)

# Box-Cox
library(MASS); bc = boxcox(lm(y~X));  lambda = bc$x[which.max(bc$y)]

# VST
lm(asin(sqrt(y)) ~ X);  lm(sqrt(y) ~ X);  lm(log(y) ~ X)

# Ridge / PCR (见 6.5, 6.6)
```

7. L9 Generalized Linear Models 广义线性模型 重点

7.1 GLM 三要素 Three Components

1. **Random**(随机分量): y_i 来自某个指数族分布(Normal / Binomial / Poisson)
2. **Systematic**(系统分量): 线性预测子 $\eta_i = \beta_0 + \sum \beta_j x_{ij}$
3. **Link**(链接函数): $g(\mu_i) = \eta_i$,即 $\mu_i = g^{-1}(\eta_i)$

模型	分布	**Link** $g(\mu)$	μ 形式	**Var**
Linear reg	Normal	identity	$\mu = \eta$	σ^2
Logistic	Bernoulli	logit $\log \frac{\mu}{1-\mu}$	$\mu = \frac{e^\eta}{1+e^\eta}$	$\mu(1-\mu)$
Poisson	Poisson	log	$\mu = e^\eta$	μ (= mean)

7.2 Logistic Regression 逻辑斯蒂回归 ★

★ 核心公式

$$\log \frac{\mu(x)}{1-\mu(x)} = \beta_0 + \beta_1 x, \qquad \mu(x) = \frac{e^{\beta_0+\beta_1 x}}{1+e^{\beta_0+\beta_1 x}}$$

Odds 几率: $O(x) = \mu(x)/[1-\mu(x)] = e^{\beta_0+\beta_1 x}$

Odds ratio 几率比(x 每增 1 单位):

$$\text{OR} = \frac{O(x+1)}{O(x)} = e^{\beta_1}$$

7.3 Logistic 推断 Inference

- **Wald z-test**(大样本,非 t!):$z = \hat{\beta}_j / SE(\hat{\beta}_j) \sim N(0,1)$
- **CI for** β_1: $\hat{\beta}_1 \pm z_{\alpha/2}\, SE(\hat{\beta}_1)$
- **CI for odds ratio**: $\exp(\text{CI for } \beta_1)$
- **Adjusted OR**: 多协变量时 e^{β_j} = 固定其他变量时 x_j 每增 1 的 OR

7.4 其他 Binomial Links(备用)

- **Probit**: $g(\mu) = \Phi^{-1}(\mu)$
- **Cloglog**: $g(\mu) = \log(-\log(1-\mu))$
- **Cauchit**: $g(\mu) = \tan(\pi(\mu - 0.5))$

7.5 Poisson Regression 泊松回归 ★

$$P(Y=y) = \frac{e^{-\mu}\mu^y}{y!}, \quad E[Y] = \text{Var}[Y] = \mu$$

$$\log \mu = \beta_0 + \beta_1 x, \qquad \mu(x) = e^{\beta_0+\beta_1 x}$$

Multiplicative change(x 增 1):

$$\frac{\mu(x+1)}{\mu(x)} = e^{\beta_1}, \qquad \%\text{ change} = (e^{\beta_1} - 1) \times 100\%$$

7.6 Offset 偏置项(Poisson 暴露量)

若每观测有不同"暴露" m_i(如人数、时间长度),用 rate $= \mu_i / m_i$:

$$\log \mu_i = \log m_i + \beta_0 + \sum_j \beta_j x_{ij}$$

$\log m_i$ 为 offset,系数固定为 1。

7.7 R 实现

```
# Logistic
fit <- glm(y ~ x1 + x2, family = binomial(link="logit"), data=d)
summary(fit); exp(coef(fit)); exp(confint(fit))   # OR and CI
predict(fit, newdata=new, type="response")         # predicted prob

# Poisson
fit <- glm(y ~ x1 + x2, family = poisson(link="log"), data=d)
# with offset:
glm(y ~ x1 + x2 + offset(log(exposure)), family=poisson, data=d)

# Model selection
library(MASS); stepAIC(fit)
```

7.8 典型例题

- **Challenger**:24 次发射,temperature → O-ring 失效。$\hat{\beta}_1 = -0.1713 \to e^{\beta_1} = 0.843$,即 temp 每升 1°F,失效 odds 降 15.7%。
- **Abdominal Aneurysms (TAA)**:n=368,covariates control/male/early/diameter。control OR=5.425, male OR=0.349, early OR=3.466。
- **Mine Fracture**:n=44,Poisson;选 $x_1 + x_2 + x_4$。

7.9 Logistic 常考题型

典型问法:

1. 给定 $\hat{\beta}_j$ 和 SE,写 Wald z 统计量并下结论
2. 解释 e^{β_j}(OR 或 OR adjusted)
3. 计算给定 x 的 $\hat{\mu}$(预测概率)
4. 给 CI for β → 求 CI for OR(取指数)
5. 模型 vs Linear probability model 的差异(LPM 预测可出 [0,1] 外,方差非常数)

8. R 输出逐行解读 Cheat-Sheet

8.1 `summary(lm)`

```
Coefficients:
            Estimate  Std.Error  t value  Pr(>|t|)
(Intercept)  95.200    1.766      53.896   1.1e-15 ***
brand2      -15.800    2.498      -6.325   3.8e-05 ***
---
Residual standard error: 9.803 on 23 degrees of freedom
Multiple R-squared: 0.988, Adjusted R-squared: 0.987
F-statistic: 918.3 on 2 and 23 DF, p-value: < 2.2e-16
```

- **Estimate** = $\hat{\beta}_j$; **Std.Error** = $SE(\hat{\beta}_j)$
- **t value** = Estimate/SE ~ t_{n-p} under H_0
- **Pr(>|t|)** 双侧 p 值;单侧须 ÷2(且方向正确)

- **Residual std. error** = $\hat{\sigma}$;**df** = $n-p$ → 反推 $n = df + p$
- **F-statistic df**: $(p-1, n-p)$ → 直接读出 p 和 n

8.2 `summary(glm)` Logistic/Poisson

```
              Estimate  Std.Error  z value  Pr(>|z|)
(Intercept)   ...       ...        ...      ...
x1            ...       ...        ...      ...
---
Null deviance:     xxx  on n-1  degrees of freedom
Residual deviance: xxx  on n-p  degrees of freedom
AIC: xxx
```

- **z value** (不是 t)= Wald 统计量
- **Null deviance** = only intercept 模型 deviance
- **Residual deviance** = 当前模型 deviance;比较两模型 $\Delta D \sim \chi^2_q$

8.3 `anova(lm_r, lm_f)`

输出 partial F: `Res.Df`, `RSS`, `Df`, `Sum of Sq`, `F`, `Pr(>F)`。

8.4 Var-Cov 矩阵使用

对 contrast $L\hat{\beta}$: $\mathrm{Var}(L\hat{\beta}) = L\,\Sigma\,L^\top$,$SE = \sqrt{\mathrm{Var}}$。

常用展开: $\mathrm{Var}(a\hat{\beta}_i + b\hat{\beta}_j) = a^2\Sigma_{ii} + b^2\Sigma_{jj} + 2ab\Sigma_{ij}$

9. 高频公式速查卡 Formula Sheet ★★★

I. 基础分布

$$\hat{\beta} \sim N(\beta,\, \sigma^2(X^\top X)^{-1});\ \frac{\hat{\beta}_j - \beta_j}{SE(\hat{\beta}_j)} \sim t_{n-p};\ \frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-p}$$

II. Multiple Comparisons

Bonferroni: $t_{n-p}(\alpha/(2k))$

Scheffé: $\sqrt{(a-1)F_{a-1,\,n-a}(\alpha)}$

Tukey: $q_{a,\,n-a}(\alpha)/\sqrt{2}$

Dunnett: 表 $d_{a,\nu,\alpha}$;unequal n 因子 $1 + 0.07(1 - n_j/n_1)$

III. General Linear F-test

$$F = \frac{(SSE_R - SSE_F)/q}{SSE_F/(n-p_F)} \sim F_{q,\,n-p_F}$$

IV. Model Selection

$R^2_a = R^2 - \frac{p}{n-p-1}(1-R^2)$

$C_p = SSE_M/\hat{\sigma}^2_{\text{full}} - n + 2|M|$

$\mathrm{AIC} = n\ln\hat{\sigma}^2_M + 2j_M$; $\mathrm{BIC} = n\ln\hat{\sigma}^2_M + j_M\ln n$

V. Diagnostics

$h_{ii} > 2p/n$ → high leverage

$r'_i = e_i/[\hat{\sigma}\sqrt{1-h_{ii}}]$; $r^*_i = r'_i\sqrt{(n-p-1)/(n-p-r'^2_i)} \sim t_{n-p-1}$

$d_i = \frac{r'^2_i}{p} \cdot \frac{h_{ii}}{1-h_{ii}}$

VI. WLS & Multicollinearity

$\hat{\beta}_W = (X^\top W X)^{-1}X^\top W y,\ w_i = 1/\sigma^2_i$

$\mathrm{VIF}_j = 1/(1-R^2_j) = SE(\hat{\beta}_j)^2\sum(x_{ji} - \bar{x}_j)^2/\hat{\sigma}^2$

Ridge: $(X^\top X + \lambda I)^{-1}X^\top y$

LASSO: $\min \frac{1}{2n}\|y - X\beta\|^2 + \lambda\|\beta\|_1$

VII. Box-Cox

$g_\lambda(Y) = (Y^\lambda - 1)/\lambda\ (\lambda \neq 0),\ \log Y\ (\lambda = 0)$

若 $\sigma \propto \mu^\alpha$: $\lambda = 1 - \alpha$

VIII. GLM

Logistic: $\log\frac{\mu}{1-\mu} = \beta_0 + \sum\beta_j x_j$; $\mathrm{OR} = e^{\beta_j}$

Poisson: $\log\mu = \beta_0 + \sum\beta_j x_j$; % change $= (e^{\beta_j} - 1) \times 100\%$

Offset: $\log\mu_i = \log m_i + \eta_i$

Wald: $z = \hat{\beta}/SE \sim N(0,1)$

10. 七种题型应答模板 Question Templates

题型	步骤
A. Multiple comparison	① 写 H_0/H_1 ② 取 $\hat{L}, SE$ 算 t^* ③ 定 critical ④ 比较下结论
B. General linear F-test(交互/子集)	① 写 $L\beta = 0$ ② Partial F 或 $L\Sigma L^\top$ ③ 查 $F_{q,n-p}$ ④ 结论
C. stepAIC 阅读	找 SSR 最大 → 候选;新 AIC 与 <none> 比
D. VIF 手算	$SE^2\sum(x-\bar{x})^2/\hat{\sigma}^2$;判严重程度;inference vs prediction
E. 诊断图阅读	Resid-Fitted:漏斗=异方差/曲线=非线性;QQ:重尾/偏;Cook/lev/rstu QQ 数极值
F. Formal outlier test	造 m 个 dummy;Bonferroni $t_{n-p-m}(\alpha/(2m))$;逐个比较 |t|
G. GLM(Logistic/Poisson)	① Wald z=$\hat{\beta}$/SE ② 解释 e^β ③ 算 $\hat{\mu}$ ④ CI 取 exp

11. 考前 48 小时 Checklist

- □ 默写 三类残差公式 + 分布
- □ 默写 **Scheffé / Tukey / Bonferroni** 的 critical value
- □ 从 `vcov` 手算任意 contrast 的 SE
- □ 读 `stepAIC` 输出,找候选,判能否加入
- □ 从 `summary(lm)` 推出 $n, p, \hat{\sigma}$
- □ 手算 **VIF**(两种等价形式)
- □ 区分 **leverage / outlier / influence**

- □ Bonferroni 同时检验 m 个 outlier 的 critical
- □ **WLS 三种权重估计**:log-log / linear / grouped
- □ **Ridge vs LASSO vs PCR** 的适用场景
- □ **Box-Cox** $\alpha \to \lambda$ 对应表
- □ **Logistic**:OR, adjusted OR, $\hat{\mu}(x)$ 的手算
- □ **Poisson**:$e^{\beta_j} - 1$ % change, offset 用法
- □ 2021 **Past paper** 完整手做一遍
- □ 打印合并讲义 **ST5202_All_Lectures_Annotated.pdf**(带批注),考前翻

12. 中英术语对照 Glossary

中文	English	中文	English
多重比较	multiple comparisons	族错误率	family-wise error rate (FWER)
对比	contrast	同步置信区间	simultaneous CI
学生化范围	Studentized range	协方差分析	ANCOVA / ANOCOV
分段线性	piecewise linear	中心化	centering
残差平方和	SSE	回归平方和	SSR
交互	interaction	哑变量	dummy variable
方差膨胀因子	VIF	多重共线性	multicollinearity
杠杆值	leverage / hat value	帽子矩阵	hat matrix
标准化残差	studentized residual (internal)	学生化删除残差	studentized deleted residual (external)
Cook 距离	Cook's distance	影响观测	influential observation
异常值	outlier	前向选择	forward selection
后向剔除	backward elimination	逐步回归	stepwise
偏差-方差	bias-variance	Mallow's Cp	Mallow's Cp
加权最小二乘	WLS	岭回归	ridge regression
套索	LASSO	自适应套索	adaptive LASSO
主成分回归	PCR	方差稳定变换	variance stabilizing transformation (VST)
Box-Cox 变换	Box-Cox transformation	广义线性模型	generalized linear model (GLM)
连接函数	link function	逻辑斯蒂回归	logistic regression
几率	odds	几率比	odds ratio
泊松回归	Poisson regression	偏置项	offset
对数似然	log-likelihood	偏差	deviance
Wald 检验	Wald test	广义交叉验证	GCV

End of Review · 祝考试顺利 Good luck!